

Leistungsanalyse

- ▶ Problemstellung
- ▶ Ziele der Leistungsanalyse
- ▶ Grundüberlegungen und Historie
- ▶ Leistungsmaße
- ▶ Amdahls Gesetz
- ▶ Einfluß der Problemgröße
- ▶ Superlinearer Speedup

Leistungsanalyse

Die zehn wichtigsten Fragen

- ▶ Was wollen wir mit der Leistungsanalyse bewerten?
- ▶ Welche Ursachen von Leistungsverlusten gibt es?
- ▶ Welche pessimistische Abschätzung machte Minsky?
- ▶ Welche zwei Maße charakterisieren typischerweise die Qualität einer Parallelisierung?
- ▶ Was beschreibt Amdahls Gesetz?
- ▶ Welchen Effekt hat ein sequentieller Anteil von $n\%$ auf die Leistungsausbeute?
- ▶ Wie verändern sich Aufwendungen von Berechnung und Kommunikation bei veränderten Datenstrukturen oder veränderter Hardware?
- ▶ Was ist superlinearer Speedup?
- ▶ Welche Formen der Parallelisierung widersetzen sich einer eindeutigen Speedup-Ermittlung?
- ▶ Wie sehen typische Speedup-Kurven aus für reale Anwendungen aus?

Problemstellung

- ▶ Beurteilung der Leistungsfähigkeit des Hochleistungsrechners
 - ▶ Hardware, Betriebssystem, Compiler
- ▶ Beurteilung der Qualität der Parallelisierung Programmierbibliotheken, Programme
- ▶ Zur Kaufentscheidung
Wieviel kostet es, wenn mein Programm in Zeit t berechnet sein muß

Ziele der Leistungsanalyse

- ▶ Optimierung der Ressourcenauslastung
Prozessoren, Speicher, Netzwerk, Platten
- ▶ Leistungsoptimierung bei exklusiven Ressourcen
Minimale Laufzeit des Programms
- ▶ Verweilzeitoptimierung bei nicht-exklusiver
Ressourcennutzung
Ebenso wichtig: Fairness zwischen den
Programmen
- ▶ Visualisierung des dynamischen Ablaufs

Grundüberlegungen

- ▶ Leistungsanalyse ist sehr komplexes Themengebiet
 - ▶ Vielfältige Literatur und Tutorials
- ▶ Hier nur einfacher Ansatz verfolgt:
 - ▶ Prozessoranzahl (space-sharing-Betrieb)
 - ▶ Programmlaufzeit (wall clock time)


Annahme: Programme nutzen Ressourcen exklusiv
- ▶ Leistungsmodellierung/Leistungsvorhersage
 - ▶ Auch kompliziert und von Bedeutung

Grundüberlegungen...

n Prozessoren, m ist maximaler Parallelismus ($m \leq n$),
l ist Leistung

Gesamte geleistete Arbeit $W = l \cdot \sum_{i=1}^n i \cdot t_i$

Durchschnittlicher Parallelismus $A = \sum_{i=1}^m i \cdot t_i / \sum_{i=1}^m t_i$



Historische Überlegungen

Anfänglich gab es sehr pessimistische Überlegungen zum Leistungspotential von Parallelrechnern

Es wurde generell das Potential zur Leistungssteigerung kritisch gesehen bzw. verneint

Aus der Menge der Aussagen betrachten wir zwei:

- ▶ Minsky, 1971
- ▶ Amdahl, 1967

Historische Überlegung: Minsky

- ▶ Ausgangspunkt

Minsky betrachtet SIMD-Systeme (Vektorrechner)

- ▶ Überlegung: Viele Programme nutzen im ersten Arbeitsschritt alle Prozessoren, dann nur noch die Hälfte, ein Viertel usw.

Beispiel: Addiere $2p$ Zahlen mit p Prozessoren

- ▶ Voraussage: Durchschnittlicher Parallelismus gleich $\text{ld}(p)$
- ▶ Bewertung: Es gibt praktisch keine Programme, die so aufgebaut sind

Leistungsmaße: Speedup und Effizienz

- ▶ Speedup: $S = T(1)/T(p)$

$T(1)$ ist die Rechenzeit auf einem Prozessor

$T(p)$ ist die Rechenzeit auf p Prozessoren

- ▶ Forderung

Wähle jeweils den schnellstmöglichen Algorithmus
(kritisch!!)

- ▶ Effizient: $E = S/p$


Normalisierung nach der Prozessorzahl. E gibt an, wieviel Prozent des maximalen Speedup $S=p$ erreicht werden

- ▶ Vermutung: $S < p$ und damit $E < 1$

Amdahls Gesetz

- ▶ Ausgangspunkt: Jedes Programm enthält einen Bruchteil f an Operationen, die nur sequentiell ausgeführt werden können
- ▶ Es gilt daher für den Speedup
$$S \leq 1/(f+(1-f)/p) \Rightarrow S_{\max} \leq 1/f$$
- ▶ Beispiel: $f=0.01 \Rightarrow S_{\max}=100$
- ▶ Praktische Erfahrung
Sequentieller Anteil meist sehr gering
- ▶ Bewertung: Amdahls Gesetz gilt! Man muss versuchen, den sequentiellen Anteil klein zu halten

Amdahls Gesetz...



Ursachen von Leistungsverlusten

▶ Zugriffsverluste

- ▶ Bei der Überwindung von Distanzen beim Datenaustausch zwischen Systemkomponenten
 - ▶ z.B. Nachrichtenaustausch oder entfernter Speicherzugriff bei NUMA

▶ Konfliktverluste

- ▶ Bei der gemeinsamen Nutzung von Ressourcen durch mehrere Programmeinheiten
 - ▶ z.B. beim Bus- und Netzzugriff

▶ Auslastungsverluste

- ▶ Bei zu geringem Parallelitätsgrad des Programms
 - ▶ z.B. permanente oder zeitweilige Lastungleichheit

Ursachen von Leistungsverlusten...

▶ Bremsverluste

- ▶ Beim Beenden gewisser Berechnungen, wenn bereits eine Lösung gefunden wurde
 - ▶ z.B. Suchbaumverfahren

▶ Komplexitätsverluste

- ▶ Durch Zusatzaufwand im parallelen Programm gegenüber dem sequentiellen
 - ▶ z.B. Aufteilung der Daten

▶ Wegwerfverluste

- ▶ Ergebnis mehrfach berechnet, aber nur eines von ihnen weiterbenutzt
 - ▶ z.B. Doppelberechnungen bei globalen Operationen

Ursache von trügerischen Leistungsgewinnen

- ▶ Geänderte Ressourcennutzung
 - ▶ Bei fester Problemgröße und steigender Anzahl Prozessoren: relevante Daten- und Code-Anteile passen auf einmal wieder in den Cache
 - => deutlich schnellere Abarbeitung

Einfluß der Problemgröße

Wir wollen nun betrachten, wie sich in verschiedenen Situationen die Aufwände für Kommunikation und Berechnung zueinander verhalten

Schwache Skalierung (weak scaling)

- ▶ Bei schwacher Skalierung behalten wir die Problemgröße **pro Prozessor** bei und erhöhen die Anzahl der Prozessoren. Die Problemgröße nimmt dabei also zu!

Starke Skalierung (strong scaling)

- ▶ Bei starker Skalierung behalten wir die gesamte Problemgröße bei und erhöhen die Anzahl der Prozessoren. Jeder hat dann zunehmend weniger zu tun – dies wird bei der Speedup-Bestimmung typischerweise zugrunde gelegt. (Amdahls Law)

Einfluß der Problemgröße...

Beispiel: Berechnung einer Matrix

- ▶ Größe: 1000×1000 Elemente
- ▶ Betrachtung eines Iterationsschrittes
- ▶ Berechnung dauert $1000 \times 1000 \times 1$ Zeiteinheit

Parallelisierung mit $p=5$

- ▶ Aufteilung in Blöcke von Zeilen
- ▶ Berechnung: $200 \times 1000 \times 1$ Zeiteinheit
- ▶ Kommunikation: benachbarte Blöcke tauschen eine Zeile aus (alle gleichzeitig)
Aufwand: $2 \times 1000 \times 1$ Zeiteinheit
- ▶ Kommunikations/Berechnungs-Verhältnis: $1/100$

Einfluß der Problemgröße...

Wir verwenden mehr Prozessoren (starke Skalierung)

Parallelisierung mit $p=10$

- ▶ Aufteilung in Blöcke von Zeilen
- ▶ Berechnung: $100 \times 1000 \times 1$ Zeiteinheit
- ▶ Kommunikation: benachbarte Blöcke tauschen eine Zeile aus (alle gleichzeitig)

Aufwand: $2 \times 1000 \times 1$ Zeiteinheit

Kommunikations/Berechnungs-Verhältnis: $1/50$

Parallelisierung mit 100 Prozessoren

- ▶ Kommunikations/Berechnungsverhältnis: $1/5$

Einfluß der Problemgröße...

Wir vergrößern das Problem (schwache Skalierung)

Parallelisierung mit $p=10$ und doppelt so großer Matrix

- ▶ Berechnung: $141 \times 1414 \times 1$ Zeiteinheit
- ▶ Kommunikation: $2 \times 1414 \times 1$ Zeiteinheit
- ▶ Kommunikations/Berechnungs-Verhältnis: $1/70$
($p=5$ und Matrix 1000×1000 : $1/100$)

Trotz doppelter Prozessoranzahl und doppelter Problemgröße verschlechtert sich das K/B-Verhältnis

Einfluß der Problemgröße...

Wir kaufen neue Prozessoren, das Netz bleibt gleich

Parallelisierung mit $p=10$ und doppelt so großer Matrix

- ▶ Berechnung: $141 \times 1414 \times 0.3$ Zeiteinheiten
- ▶ Kommunikation: $2 \times 1414 \times 1$ Zeiteinheit
- ▶ Kommunikations/Berechnungs-Verhältnis: $1/21$

Zu dumm: die Effizienz der Parallelisierung wurde dadurch verschlechtert!

Superlinearer Speedup

Aufgabenstellung

- ▶ n Sortieralgorithmen mit Laufzeiten t_i
- ▶ Finde den besten Sortieralgorithmus

Sequentielles Programm

- ▶ Lasse den ersten Algorithmus laufen; liefert $t_{\min} = t_1$
- ▶ Starte nächsten Algorithmus; wenn er t_{\min} überschreitet, dann sofort stoppen; andernfalls $t_{\min} = t_j$
- ▶ Wiederhole mit allen Algorithmen
- ▶ Zeitbedarf $t_{\text{seq}} \geq t_{\min} \times n$

Superlinearer Speedup...

Paralleles Programm

- ▶ Nimm n Prozessoren
- ▶ Starte n Algorithmen gleichzeitig auf den Prozessoren
- ▶ Stoppe die Berechnung, wenn der erste fertig ist
- ▶ Zeitbedarf: $t_{\text{par}} = t_{\text{min}}$

Erzielter Speedup: $S = t_{\text{seq}} / t_{\text{par}} \Rightarrow S \geq n$!?

Perpetuum mobile des parallelen Rechnens?

Superlinearer Speedup...

Analyse des Beispiels:


- ▶ Sequentielles Programm ist nicht „das schnellstmögliche“ sequentielle Programm
- ▶ Speedup-Definition fordert „schnellstmögliches“ Programm
- ▶ „Schnellstmöglich“ hier: quasiparallele Abarbeitung des Algorithmusvergleich auf einem Prozessor
- ▶ Damit verschwindet dann der superlineare Speedup

Superlinearer Speedup...


Suchbaum-Verfahren sequentiell/parallel

- Wir suchen **eine** Lösung

Fall 1





sequentiell



parallel

Fall 2



Superlinearer Speedup...

Analyse des Beispiels:

- ▶ Für breite Bäume geht im Fall a) der Speedup gegen unendlich
- ▶ Für breite Bäume geht im Fall b) der Speedup gegen eins

Angabe des Speedup sinnlos!


Parallelisierung ebenso?

Bei Suche nach allen Lösungen problemlos!

- ▶ Hier verschwindet das Problem

Speedup-Bestimmung

Verwendet in wissenschaftlichen Artikeln, in denen die Verfahren parallelisiert wurden



Speedup-Bestimmung...

Speedup-Kurven angegeben für festen Datensatz Kurvenverlauf

- ▶ Bei guten numerischen Verfahren
S nahe bei p für alle p, die wir einsetzen
Effizienz zwischen 80% und 100%
- ▶ Bei schlechten Verfahren
Effizienz von 50% oder schlechter

Was tun, wenn die Kurven nicht optimal aussehen?

Speedup-Bestimmung...

David Bailey

*Twelve Ways to Fool the Masses When Giving
Performance Results on Parallel Computers*

Supercomputer Review, August 1991

Liste sehr beliebter (Selbst-)Täuschungsmethoden zur
Erzielung besserer Ergebnisse

Speedup-Bestimmung...

- (2) Present performance figures for an inner kernel, and then represent these figures as the performance of the entire application
- (4) Scale up the problem size with the number of processors, but omit any mention of this fact
- (5) Quote performance results projected to a full system
- (7) When direct run time comparisons are required, compare with an old code on an obsolete system

Speedup-Bestimmung...

(12) If all else fails, show pretty pictures and animated videos, and don't talk about performance

Leistungsanalyse

Zusammenfassung

- ▶ Leistungsanalyse dient der Rechner- und Programmbewertung
- ▶ Es gibt unterschiedliche Ursachen für Leistungsverluste
- ▶ Speedup und Effizienz charakterisieren die Qualität des parallelen Programms
- ▶ Amdahl: der Speedup ist nach oben begrenzt
- ▶ Problemgröße beeinflusst den erreichbaren Speedup
- ▶ Superlinearer Speedup ist nicht systematisch nutzbar
- ▶ Es gibt viele Möglichkeiten für irrtümlich oder absichtlich falsche Speedup- bzw. Leistungs-Angaben